

MIOwAD: Sieci Kohonena

Kacper Staroń 298842

27.04.2021

1 Temat laboratoriów

Tematem tej części laboratoriów było zaimplementowanie i przetestowanie na różnych dostępnych zbiorach mapy Kohonena w problemie klasyfikacji. Istotne było zaimplementowanie różnych hiperparametrów, takich jak:

- architektura mapy (kwadratowa, sześciokątna)
- funkcje sąsiedztwa (gaussowska, "meksykański kapelusz")
- szerokość sąsiedztwa

2 Przebieg laboratoriów

Laboratorium było podzielone na dwie części.

2.1 Tydzień 1.

W 1. tygodniu celem było zaimplementowanie podstawowej mapy Kohonena o kwadratowej architekturze i z dwoma funkcjami sąsiedztwa oraz przetestowanie jej na dostarczonych zbiorach wektorów dwu- i trzowymiarowych, odpowiednio zbiory Hexagon i Cube.

2.1.1 Hexagon

Zbiór Hexagon składa się z punktów na płaszczyźnie zebranych w 6 chmur punktów.

Dla 6 neuronów odpowiadających 6 klasom zarówno dla funkcji gaussowskiej (fig.1) jak i `mexican_hat` (fig.2) otrzymujemy zadowalające dopasowania, oba z homogeneity score na poziomie ok. 0.92.

Poniższe klasyfikacje zostały uzyskane dla sąsiedztwa o szerokości 1. Dodatkowo przeanalizowana została jakość dopasowania (dalej przy użyciu homogeneity score) dla różnych szerokości sąsiedztwa (fig.3) - możemy zaobserwować nagle załamanie wyniku dla wartości 0.5, ale poza tym wartości są do siebie zbyt zbliżone by możliwe było głębsze wnioskowanie.




Figure 1: Gauss




Figure 2: mexican_hat




Figure 3: homogeneity score w zależności od szerokości sąsiedztwa




Figure 4: 9 klas - neuronów




Figure 5: 6 klas

Przeprowadzono eksperyment dla większej liczby neuronów niż nominalna liczba klas polegający na przeprowadzeniu uczenia i klasyfikacji dla większej mapy (w tym przypadku 3x3) i klasteryzacji neuronów do szukanej liczby klas (w tym przypadku klasteryzacja nie była kluczowym elementem eksperymentu, zostało więc zastosowane rozwiązanie naiwne).

Możemy zaobserwować relatywnie wysoka jakość tak uzyskanego dopasowania. Dobór bardziej zaawansowanego i dostrojonego do problemu algorytmu klasteryzacji neuronów prawdopodobnie doprowadziłby do niemal bezbłędneho rozwiązania.

2.1.2 Cube

Zbiór Cube jest zbiorem punktów w przestrzeni trójwymiarowej podzielonych na 8 wyróżnialnych chmur. Ze względu na postać zbioru ominięto etap nieczytelnej wizualizacji zbioru i od razu przedstawiamy wyniki analiz jakości klasyfikacji.

Obie funkcje sąsiedztwa ponownie uzyskały wysokie wyniki na poziomie 0.90 homogeneity score i na tyle zbliżone, że niemożliwe jest stwierdzenie wyraźnej przewagi którejś z metod.

Na fig. 6 analiza jakości dopasowania dla różnych szerokości sąsiedztwa przy zastosowaniu funkcji gaussowskiej i 8 neuronów w sieci. Obserwujemy, że wartości są do siebie zbyt zbliżone by możliwe było głębsze wnioskowanie.




Figure 6: homogeneity score w zależności od szerokości sąsiedztwa

2.2 Tydzień 2.

W 2. tygodniu celem było zaimplementowanie dodatkowej mapy o architekturze sześciokątnej i przetestowanie całej zaimplementowanej sieci na dwóch kolejnych zbiorach, tym razem większych objętościowo i o obserwacjach z przestrzeni wielowymiarowych (UCI HAR), w tym reprezentacji obrazów (MNIST).

2.2.1 MNIST

Zbiór MNIST zawiera obrazy (28px x 28px) ręcznie zapisanych cyfr (10 klas) jako ciągi pixeli w skali szarości, o wartościach z przedziału (0, 1).

Poniżej zapisane wartości jakości dopasowania dla różnych hiperparametrów (eksperymenty przeprowadzone dla 10 neuronów, szerokości sąsiedztwa 0.5, 10 epok).

Homogeneity score:

	gauss	mexican_hat
square	0.321	0.324
hexagon	0.322	0.345

Completeness score:

	gauss	mexican_hat
square	0.360	0.345
hexagon	0.423	0.432

Najwyższe wyniki obserwujemy dla sieci sześciokątnej z funkcją sąsiedztwa `mexican_hat`. Przeprowadzimy dla niej bardziej szczegółową analizę szerokości sąsiedztwa.




Figure 7: homogeneity score w zależności od szerokości sąsiedztwa

W przeciwieństwie do analiz z tygodnia 1. obserwujemy ewidentny wzrost efektywności dopasowania wraz z wzrostem szerokości sąsiedztwa.

2.2.2 UCI HAR

Zbiór UCI HAR zawiera 561-elementowe wektory przydzielone do 6 klas.

Poniżej zapisane wartości jakości dopasowania dla różnych hiperparametrów (eksperymenty przeprowadzone dla 10 neuronów, szerokości sąsiedztwa 0.5, 10 epok).

Homogeneity score:

	gauss	mexican_hat
square	0.514	0.469
hexagon	0.600	0.595

Completeness score:

	gauss	mexican_hat
square	0.581	0.659
hexagon	0.735	0.782

Najwyższe wyniki obserwujemy dla sieci sześciokątnej z funkcją sąsiedztwa `mexican_hat`. Przeprowadzimy dla niej bardziej szczegółową analizę szerokości sąsiedztwa.




Figure 8: homogeneity score w zależności od szerokości sąsiedztwa

Obserwujemy istotny spadek efektywności dopasowania dla konkretnych wartości szerokości sąsiedztwa.

3 Wnioski końcowe

Zaimplementowana prosta sieć Kohonena okazała się istotnie efektywnym sposobem na klasyfikację. W przeanalizowanych przypadkach widzimy, że nawet bez precyzyjnego strojenia dla prostych (o małej liczbie wymiarów) zbiorów osiąga bardzo wysokie wyniki.

Także dla bardziej zaawansowanych zbiorów sieć przy odpowiednio dobranej architekturze i funkcji sąsiedztwa osiągała relatywnie wysokie wyniki rzędu nawet 0.7 homogeneity/completeness score mimo braku strojenia i relatywnie niewielkiej liczbie epok uczenia.

Wyniki eksperymentów wskazują także jednoznacznie na przewagę sieci o sześciokrotnym ułożeniu neuronów nad ułożeniem kwadratowym w analizowanych problemach. Prawdopodobnie dobór jeszcze innej architektury mógłby być istotnym elementem strojenia przy bardziej zaawansowanych indywidualnych zastosowaniach map Kohonena.